

Öneri Sistemleri Final Ödevi - IGMC Uygulama Raporu

ÖNERİ SİSTEMLERİ FİNAL ÖDEVİ

Inductive Graph-Based Matrix Completion (IGMC) ile MovieLens-100K Üzerinde Öneri Sistemi Uygulaması

Referans Makale:

*Zhang, M. & Chen, Y. (2020). Inductive Matrix Completion Based on Graph Neural Networks.
International Conference on Learning Representations (ICLR 2020).*

Özlem AKINCI

258102029

Dönem: 2025 – 2026 Bahar

Özet

Bu raporda, öneri sistemlerinde matris tamamlama problemi için Zhang ve Chen (2020) tarafından önerilen Inductive Graph-based Matrix Completion (IGMC) yöntemi incelenmiş ve MovieLens-100K veri seti üzerinde uygulanmıştır. IGMC, kullanıcı-öğre etkileşimlerini iki parçalı bir graf olarak ele alır; hedef kullanıcı-öğre çifti etrafından 1-hop enclosing subgraph çıkarır, hedef kenarı gizler ve R-GCN tabanlı bir grafik sinir ağı ile rating tahmini yapar. Çalışmada baseline olarak NumPy ile sıfırdan yazılmış Matrix Factorization / Funk-SVD kullanılmıştır. Deneylerde 5-fold cross-validation, RMSE ve MAE metrikleri, üç farklı öğrenme oranı ve iki ablation varyasyonu raporlanmıştır. Elde edilen sonuçlarda IGMC, MF baseline modelinden daha düşük hata vermiştir. IGMC ortalama RMSE değeri 1.0099, MF baseline ortalama RMSE değeri ise 1.2489 olarak elde edilmiştir. Orijinal makaledeki ML-100K RMSE değeri 0.905 olduğundan, uygulama sonuçları makaledeki eğilimle uyumlu olmakla birlikte daha kısa eğitim süresi ve %30 örneklem kullanımı nedeniyle daha yüksek hata üretmiştir.

1. Giriş

Öneri sistemleri, kullanıcıların geçmiş etkileşimlerinden yararlanarak henüz puanlamadıkları ürünler, filmler veya içerikler hakkında tahmin üretmeyi amaçlar. Bu problem çoğunlukla matris tamamlama olarak modellenir: kullanıcılar matrisin satırlarını, öğeler sütunlarını ve gözlenen rating değerleri de matrisin dolu hücrelerini temsil eder. Amaç, boş hücrelerdeki muhtemel rating değerlerini tahmin etmektir.

Geleneksel matris tamamlama yöntemleri (örneğin Funk-SVD tabanlı Matrix Factorization) transduktif öğrenmeye dayanır; yani modeli eğitirken tüm kullanıcı ve öğe gömme vektörlerini (embeddings) büyük bir matris içinde saklarlar. Ancak bu transductive yapılı yaklaşım eğitimde görülmeyen yeni kullanıcı veya öğeler için doğrudan genelleme yapmakta zorlanır. Seçilen IGMC makalesi bu soruna, kullanıcı ve öğe kimliklerini ezberlemek yerine hedef kullanıcı-öğesi çifti etrafındaki lokal grafik örüntülerini öğrenerek çözüm üretmektedir.

Bu ödev kapsamında amaç, IGMC makalesini analiz etmek, yöntemin temel mantığını Python ile uygulamak ve yöntemi bir baseline modelle karşılaştırmaktır. Rapor; makale analizi, yöntem açıklaması, deneysel kurulum, sonuçlar, ablation çalışması ve makale ile karşılaştırma bölümlerinden oluşmaktadır.

2. Makale Analizi

2.1 Problem Tanımı

Makalenin problemi, yalnızca rating matrisi kullanılarak inductive matrix completion yapmaktır. Kullanıcı ya da film türü, yaş, cinsiyet, içerik açıklaması gibi ek side information kullanılmadan, gözlenmeyen kullanıcı-öğesi rating değerlerinin tahmin edilmesi hedeflenir. Makalenin temel iddiası, hedef rating etrafındaki lokal iki parçalı graf yapısının, rating tahmini için yeterli ve anlamlı örüntüler taşıdığıdır.

Matris tamamlama problemi, kısmen gözlemlenmiş bir $U \times I$ rating matrisindeki eksik değerleri tahmin etmektir. Kullanıcı u ve öğesi i arasındaki bilinmeyen derecelendirme $r_{\{u,i\}}$ tahmin edilmek istenmektedir. Klasik model tabanlı yaklaşımlarda:

$$R \approx U \cdot V^T$$

Formül 1

Formül 1 (MF yaklaşımı) şeklinde matris ayrıştırması yapılır. Ancak IGMC, bu global yapıyı öğrenmek yerine her (u, i) çifti için lokal bir alt grafı inceleyerek inductif tahmin üretir

2.2 Önerilen Yöntem: IGMC

IGMC üç temel bileşenden oluşmaktadır:

- Enclosing Subgraph Çıkarımı: Hedef (u, i) çifti için BFS algoritması ile genişletilen, r dereceli grafı çıkarılır.
- Node Labeling: Çıkarılan alt grafın her düğümüne aşağıdaki 4 sınıflı one-hot etiket atanır:
 - Hedef kullanıcı (u): $[1, 0, 0, 0]$
 - Hedef öğesi (i): $[0, 1, 0, 0]$
 - Diğer kullanıcılar: $[0, 0, 1, 0]$
 - Diğer öğeler: $[0, 0, 0, 1]$
- R-GCN ile Mesaj İletimi: Her ilişki türü r (1–5 arası rating değerleri) için ayrı dönüşüm matrisleri kullanılır.

R-GCN katmanının temel denklemi (formül 2):

$$h^{(l+1)} = \sigma(W_{self} \cdot h^{(l)} + \sum_r D_r^{-1} A_r \cdot h^{(l)} \cdot W_r)$$

Formül 2: R-GCN katmanı denklemi

Burada A_r , r . rating değerine sahip kenarların seyrek komşuluk matrisi; D_r ise derece normalizasyon matrisidir. Hesaplama maliyetini düşürmek için basis-decomposition uygulanır (formül 3):

$$W_r = \sum_b \text{coeff}_{\{r,b\}} \cdot \text{Basis}_b$$

Formül 3: Basis-decomposition

4 katmanlı R-GCN ardından hedef kullanıcı ve öge gömme vektörlerinin concatenation'ı MLP'ye girdi olarak verilir ve skalar rating tahmini üretilir.

Alt graf çıkarıldıktan sonra node labeling uygulanır. Makalede hedef kullanıcı ve hedef öge özel etiketlerle, diğer kullanıcı ve öğeler ise hedefe uzaklıklarına göre etiketlenir. Bu uygulamada hop=1 seçildiğinden, hedef kullanıcı, hedef öge, diğer kullanıcılar ve diğer öğeler için 4 sınıflı one-hot etiketleme kullanılmıştır. Ardından R-GCN katmanları farklı rating tiplerini farklı ilişki türleri gibi işleyerek mesaj iletimi yapar. Son aşamada hedef kullanıcı ve hedef ögenin temsil vektörleri birleştirilir ve MLP ile rating tahmini üretilir.

2.3 DeneySEL Kurulumun Özeti

Orijinal makale Flixster, Douban, YahooMusic, MovieLens-100K ve MovieLens-1M veri setlerinde deney yapmıştır. ML-100K için 943 kullanıcı, 1.682 öge ve 100.000 rating kullanılmıştır. Makale, IGMG modelini GC-MC, F-EAE, PinSage ve diğer matris tamamlama modelleriyle karşılaştırmış; ML-100K üzerinde RMSE 0.905 sonucunu raporlamıştır. Bu sonuç, IGMG'nin side information kullanmadan da rekabetçi performans verebildiğini göstermektedir.

2.4 Seçilen Makalenin Güçlü ve Zayıf Yönleri

Güçlü Yönler

- İnduktif Öğrenme: Eğitim setinde görülmemiş kullanıcı/öge çiftleri için tahmin üretilebilir (cold-start'a karşı dirençli).
- Yerel Yapı Kullanımı: Global gömme vektörlerine ihtiyaç duymadan lokal grafların bilgisinden yararlanır.
- ARR Düzenleştirme: Rating ordinalitesini modelleyerek daha anlamlı bir sıralama öğrenmesini sağlar.
- Ölçeklenebilir Parametre Sayısı: Basis-decomposition ile R-GCN parametreleri makul boyutlarda tutulur.

Zayıf Yönler

- Yüksek Çıkarsama Maliyeti: Her tahmin için ayrı bir enclosing subgraph çıkarılması, özellikle büyük veri setlerinde ciddi hesaplama yükü oluşturur.
- Küçük Grafların Sınırlılığı: Seyrek veri setlerinde alt graflar çok küçük kalabilir, bu da mesaj iletiminin etkinliğini düşürür.
- Hiperparametre Duyarlılığı: Hop sayısı, gizli boyut ve ARR katsayısı ayarlamasının her veri seti için ayrı yapılması gerekmektedir.
- Bellek Tüketimi: RAM'e tüm alt grafları önbelleğe alma yaklaşımı büyük veri setlerinde uygulanabilir olmayabilir.

3. Yöntem

Uygulama Python ve PyTorch kullanılarak sıfırdan (from scratch) gerçekleştirilmiştir. Kod dört ana modüle ayrılmıştır:

- Veri Hazırlığı ve 5-Fold CV kurulumu (Hücre 1)
- Matrix Factorization Baseline — Funk-SVD tabanlı SGD implementasyonu (Hücre 3)
- IGMC Bileşenleri — SparseRGCNLayer, alt graf çıkarımı, IGMC_Model (Hücreler 5–7)
- Eğitim, LR sweep, ablation çalışması ve görselleştirme (Hücre 9)

3.1 Veri Hazırlığı

Uygulamada MovieLens-100K veri seti GroupLens kaynağından okunmuştur, veri seti lokal kaynağa indirilmemiştir. Veri setinde kullanıcı ID, item ID, rating ve timestamp alanları bulunmaktadır. Kullanıcı ve item ID değerleri sıfırdan başlayan indekslere dönüştürülmüştür. Hesaplama süresini azaltmak amacıyla rating dağılımı korunarak %30 stratified örnekleme yapılmış ve deneyler 30.000 rating üzerinde yürütülmüştür. Bu yöntemin kullanılmasının amacı matris yapısının ve k-fold çaprazlamanın 100.000 adet veri ile her fold eğitiminde yaklaşık 5.5 saati alması ve genel eğitim süresinin günlere yayılması sebebiyledir. Kısacası zaman maliyeti sebebi ile dağılım korunarak verinin %30'u ile örnekleme yapılmıştır. Veri seti hakkında bilgiler ve deneyler için hazırlanan indisler tablo 1'de aktarılmıştır.

Özellik	Değer
Orijinal kullanıcı sayısı	943
Orijinal item/film sayısı	1.682
Orijinal rating sayısı	100.000
Kullanılan örneklem	30.000 rating (%30 stratified)
Rating aralığı	1-5
Cross-validation	5-fold
Seed	42

Tablo 1: Veri Hazırlığı İndeksleri

3.2 Enclosing Subgraph Çıkarımı

Her hedef (u, v) kullanıcı-öge çifti için 1-hop çevresindeki kullanıcılar ve ögeler alınarak lokal alt graf oluşturulmuştur. Alt graf oluşturulduktan sonra hedef rating kenarı kaldırılmıştır. Bu işlem önemlidir; çünkü hedef kenar kaldırılmazsa model tahmin etmesi gereken rating değerini doğrudan görmüş olur.

Bu makalede klasik item-based veya user-based CF yöntemlerinde olduğu gibi Pearson, cosine veya Euclidean gibi sabit bir benzerlik metriği kullanılmaz. Benzerlik/uzaklık bilgisinin karşılığı, R-GCN katmanları tarafından öğrenilen lokal grafik örüntüleridir. Yani model, komşu seçimini el ile tanımlanmış bir similarity metriğiyle değil, hedef rating etrafındaki etiketli bağlantı yapısından öğrenir.

3.3 R-GCN Mesaj İletimi ve Tahmin Fonksiyonu

R-GCN katmanında her rating tipi ayrı bir ilişki türü olarak işlenir. Temel mesaj iletimi aşağıdaki gibidir (formül 4):

$$x_i^{(l+1)} = W_{\theta}^{(l)} x_i^{(l)} + \sum_{r \in R} \sum_{j \in N_r(i)} (1 / |N_r(i)|) W_r^{(l)} x_j^{(l)}$$

Formül 4: Temel mesaj iletimi

Katman çıktıları birleştirilerek her düğüm için nihai temsil formül 5 ile elde edilir:

$$h_i = \text{concat}(x_i^1, x_i^2, \dots, x_i^L)$$

Formül 5: Nihai temsil için kullanılan formül

Graf düzeyi temsil olarak yalnızca hedef kullanıcı ve hedef öge temsilleri birleştirilme işlemleri formül 6 ile elde edilir:

$$g = \text{concat}(h_u, h_v)$$

Formül 6: Graf düzeyinde temsil için kullanılan formül

Son tahmin formül 7 ile MLP tarafından üretilir:

$$r_{\text{hat}} = w^T \sigma(Wg)$$

Formül 7: Mlp tarafından üretilen son tahmin

3.4 Kayıp Fonksiyonu ve Değerlendirme Metrikleri

Model eğitiminde temel hata fonksiyonu MSE olarak alınmıştır (Formül 8):

$$L = (1 / |\Omega|) \sum_{(u,v) \in \Omega} (R_{uv} - R_{\text{hat}_{uv}})^2$$

Formül 8: MSE

Değerlendirme için RMSE ve MAE kullanılmıştır. RMSE büyük hataları daha fazla cezalandırır; MAE ise ortalama mutlak sapmayı daha doğrudan gösterir (Formül 9 ve 10).

$$\sqrt{(1/n) \sum_i (y_i - y_{\text{hat}_i})^2}$$

Formül 9: RMSE

$$(1/n) \sum_i |y_i - y_{\text{hat}_i}|$$

Formül 10: MAE

3.5 Baseline: Matrix Factorization / Funk-SVD

Baseline model olarak kullanıcı ve item gizli vektörlerini öğrenen Matrix Factorization yaklaşımı kullanılmıştır.

Bu modelde tahmin (formül 11), kullanıcı vektörü ile item vektörünün iç çarpımıdır:

$$R_{\text{hat}_{ui}} = U_u \cdot V_i$$

Formül 11: Matrix Factorization

Model NumPy ile sıfırdan yazılmış ve SGD ile eğitilmiştir. Öğrenme oranı 0.005, regularization 0.02, latent boyut k=20 ve epoch sayısı 20 olarak kullanılmıştır.

4. DeneySEL Kurulum

DeneySEL kurulum, ödev kriterlerini karşılayacak şekilde baseline karşılaştırması, 5-fold cross-validation, üç farklı hiperparametre değeri ve ablation çalışmasını içerecek biçimde tasarlanmıştır. Tüm rastgelelik kaynakları numpy, PyTorch ve Python random için seed=42 ile sabitlenmiştir (Tablo 2).

Dört önemli hız optimizasyonu uygulanmıştır:

- OPT-1: Alt graflar yalnızca bir kez hesaplanarak RAM'e önbelleğe alınmaktadır; 5 fold boyunca yeniden hesaplama yapılmamaktadır.
- OPT-2: Erken durdurma (patience=2) ile gereksiz epoch tekrarı engellenmektedir.
- OPT-3: LR sweep ve ablation deneyleri aynı fold-0 önbelleğini paylaşarak ek hesaplama maliyeti oluşturmamaktadır.

Öneri Sistemleri Final Ödevi - IGMC Uygulama Raporu

- OPT-4: batch_size=128 kullanılarak epoch başı optimizasyon adım sayısı azaltılmıştır.

Bileşen	Ayar
Ana model	IGMC - 4 katmanlı R-GCN + hedef düğüm concatenation + MLP
Input node feature	4 sınıflı one-hot node labeling
Hidden dimension	32
R-GCN katman sayısı	4
Hop sayısı	1-hop enclosing subgraph
Batch size	128
Optimizer	Adam
CV öğrenme oranı	0.001
Epoch	Maksimum 5 epoch
Early stopping	patience=2
LR sweep	0.001, 0.005, 0.01
Ablation	w/o ARR, w/o Node Labeling
Metrikler	RMSE, MAE

Tablo 2: Deneyisel kurulum aşamasında kullanılan bileşenler

Not: Kodda kullanılan ARR terimi, makaledeki adjacent rating regularization fikrinin sadeleştirilmiş/ordinal bir uygulama varyasyonu olarak ele alınmıştır. Bu nedenle ablation yorumları, mevcut kod uygulamasının etkisini göstermektedir.

5. Sonuçlar ve Tartışma


5.1 5-Fold Cross-Validation Sonuçları

Fold	MF RMSE	MF MAE	IGMC RMSE	IGMC MAE
1	1.2240	0.9608	0.9940	0.7847
2	1.2452	0.9777	1.0134	0.8206
3	1.2382	0.9655	1.0229	0.8286
4	1.2419	0.9753	1.0059	0.8115
5	1.2951	1.0189	1.0135	0.8178
Ortalama	1.2489	0.9796	1.0099 ± 0.0096	0.8126

Tablo 3: 5-fold cross validation sonuçları

Tablo 3 ve şekil 1’de gösterilen sonuçlara göre IGMC modeli, tüm fold ortalamasında MF baseline modelinden daha düşük RMSE ve MAE üretmiştir. RMSE açısından iyileşme yaklaşık %19.1 düzeyindedir: $(1.2489 - 1.0099) / 1.2489 \approx 0.191$. Bu sonuç, lokal graf örüntülerinin sadece gizli vektör çarpımına dayalı baseline modelden daha açıklayıcı olduğunu göstermektedir.

MF Baseline - IGMC - Makale RMSE Karşılaştırması



Şekil 1. MF baseline, uygulanan IGMC ve orijinal makale RMSE karşılaştırması.

5.2 Hiperparametre Deneyi: Öğrenme Oranı

Öğrenme Oranı	Best RMSE	MAE	Yorum
0.001 (Referans)	0.9917	0.7823	Kararlı fakat daha yavaş iyileşme
0.005	0.9734	0.7669	Daha hızlı yakınsama
0.01	0.9723	0.7690	En düşük RMSE, ancak daha dalgalı olabilir

Tablo 4: Hiperparametre deneyi sonuçları

Fold-0 üzerinde yapılan öğrenme oranı süpürmesinde en düşük RMSE 0.01 öğrenme oranında elde edilmiştir. Buna karşın 0.005 değeri de çok yakın bir sonuç vermiştir. Bu nedenle uzun eğitim yapılacaksa 0.005 daha dengeli bir seçim olabilir; kısa eğitim bütçesinde ise 0.01 daha hızlı iyileşme sağlamıştır (Tablo 4).


5.3 Ablation Study

Yöntemin her iki temel bileşeninin katkısı, söz konusu bileşeni devre dışı bırakarak ölçülmüştür (Tablo 4):

Varyasyon	RMSE	MAE	Değerlendirme
Full IGMC	0.9946	0.7905	Referans model
w/o ARR ($\lambda_{arr} = 0$)	0.9870	0.7888	Bu kısa eğitimde sadeleştirilmiş ARR katkısı sınırlı kalmıştır
w/o Node Labeling	1.0160	0.8163	Node labeling kaldırılınca performans kötüleşmiştir

Tablo 5: Ablation çalışması ve sonuçları

Tablo 5 ablation çalışması sonuçlarını aktarmaktadır. Ablation sonucunda node labeling bileşeninin önemli olduğu görülmektedir. Node labeling kaldırıldığında model, hedef kullanıcıyı, hedef öğeyi ve bağlam düğümlerini ayırt etmekte zorlanır; bu da RMSE değerini artırmıştır. Sadeleştirilmiş ARR varyasyonunda ise full modele göre küçük bir iyileşme görülmüştür (Şekil 2). Bu durum, kısa eğitim süresi, düşük epoch sayısı ve kodda kullanılan ARR varyasyonunun makaledeki parametre-matrisi düzenliştirmesinden daha basit olmasıyla açıklanabilir.



Şekil 2. Ablation study sonuçları.

5.4 Makale Sonuçlarıyla Karşılaştırma

Kaynak / Model	Veri	Kurulum	RMSE
Zhang & Chen (2020) - IGMC	ML-100K	Orijinal makale kurulumu, 30-50 epoch, dim=64	0.905
Bu uygulama - IGMC	ML-100K %30 örneklem	5-fold CV, max 5 epoch, hidden_dim=32	1.0099
Bu uygulama - MF baseline	ML-100K %30 örneklem	5-fold CV, k=20, 20 epoch	1.2489

Tablo 6: İncelenen makale ve yapılan çalışmanın karşılaştırılması

Uygulama sonucu orijinal makaledeki RMSE değerinden yüksek olduğu tablo 6'da görülmektedir. Bunun temel nedenleri şunlardır: (1) orijinal makale daha uzun eğitim ve daha kapsamlı deneysel ayarlar kullanmıştır; (2) bu çalışmada çalışma süresini azaltmak için %30 örneklem kullanılmıştır; (3) epoch sayısı maksimum 5 ile sınırlandırılmıştır; (4) node labeling ve ARR bileşenleri kodda sadeleştirilmiş biçimde uygulanmıştır. Buna rağmen IGMC'nin baseline modelden daha iyi performans vermesi, makaledeki ana eğilimle uyumludur.

5.5 Genel Tartışma

MF baseline yalnızca kullanıcı ve item gizli vektörlerinin iç çarpımına dayanır. IGMC ise hedef rating etrafındaki yerel komşuluk yapısını ve farklı rating türlerine bağlı bağlantı örüntülerini kullanır. Bu nedenle özellikle kullanıcıların ortak izleme/puanlama örüntülerinin önemli olduğu durumlarda daha zengin temsil öğrenebilir. Ancak IGMC'nin hesaplama maliyeti daha yüksektir; çünkü her hedef çift için alt graf çıkarılması ve GNN üzerinden işlenmesi gerekir.

Bu çalışmanın en önemli sınırlılığı, hesaplama süresini azaltmak için tam 100.000 rating yerine 30.000 rating kullanılmasıdır. Ayrıca full_cache yaklaşımı çalışma süresini azaltmak için tüm örneklerin alt grafını tek seferde hesaplar. Akademik olarak daha katı bir deneyde her fold için yalnızca eğitim verisinden rating grafi kurulması daha güvenli olur. Bu geliştirme, ilerideki sürümde veri sızıntısı riskini azaltmak için uygulanabilir.

6. Sonuç

Bu ödevde IGMC makalesi incelenmiş, temel yöntem Python/PyTorch ile uygulanmış ve MovieLens-100K üzerinde baseline Matrix Factorization modeliyle karşılaştırılmıştır. Deneyler, IGMC'nin MF baseline modelinden daha düşük hata verdiğini göstermiştir. 5-fold CV ortalamasında IGMC RMSE=1.0099 ve MAE=0.8126 sonucuna ulaşırken, MF baseline RMSE=1.2489 ve MAE=0.9796 üretmiştir. Üç farklı öğrenme oranı denenmiş, ablation study ile node labeling bileşeninin etkisi gösterilmiş ve sonuçlar grafiklerle desteklenmiştir.

Genel olarak IGMC, öneri sistemlerinde yalnızca rating matrisinden öğrenen, side information gerektirmeyen ve lokal grafik örüntülerini kullanan güçlü bir yaklaşımdır. Bu çalışma, teorik makale bilgisinin gerçek bir veri seti üzerinde uygulanması, baseline karşılaştırması yapılması ve deneysel sonuçların eleştirel biçimde yorumlanması açısından ödev kriterlerini karşılamaktadır.

7. Kaynakça

Zhang, M. ve Chen, Y. (2020). Inductive Matrix Completion Based on Graph Neural Networks. International Conference on Learning Representations (ICLR).

Funk, S. (2006). *Netflix Update: Try This at Home*. sifter.org/simon/journal/20061211.html.

GroupLens Research. MovieLens 100K Dataset. University of Minnesota.

Harper, F. M. & Konstan, J. A. (2015). *The MovieLens Datasets: History and Context*. ACM Transactions on Interactive Intelligent Systems, 5(4).

Koren, Y., Bell, R. ve Volinsky, C. (2009). Matrix Factorization Techniques for Recommender Systems. Computer, 42(8), 30-37.

Schlichtkrull, M., Kipf, T. N., Bloem, P., van den Berg, R., Titov, I. ve Welling, M. (2018). Modeling Relational Data with Graph Convolutional Networks.